

# 李宇晗

🏠 浙江大学 · 🎓 计算机科学与技术

☎ (+86) 183-4606-7916 · ✉ 3188127343@qq.com · 📠 微信: lyh20060321lyh

🌐 github.com/YH7916 · 🌐 yohaku.codes



找日常实习，可随时到岗，实习时间三个月

## 🎓 教育背景

2024.08 | 浙江大学·计算机科学与技术学院·本科(大二在读)；高考 694 分

2028.06 | CET-4, CET-6；浙江大学 ZipLab 科研实习生

## 🧰 实习经历

智启纳威 (AI Native 初创公司)

AI Agent 开发实习

2026 年 3 月 - 至今

Python, FastAPI, TypeScript, MCP, CLI, Skill, Provider, Benchmark

- 构建模型 Benchmark 体系，覆盖 TTFT / 流式耗时、工具调用、视觉输入与业务任务效果评测，沉淀不同 provider 的延迟、稳定性与能力边界对比。
- 独立构建 CLI / MCP 外部 Agent 调用链路，将后端能力封装为可被 Claude Code / Codex / OpenClaw 调用的本地工具，并最终落地 CLI + Skill 完整链路。
- 参与业务 Skill 落地，建设飞书 CLI 安装/授权与上下文同步 Skill，降低外部 Agent 配置成本。

## </> 项目经历

CuteGo - 端侧围棋 AI 应用

全栈项目

2026 年 1 月 - 2026 年 3 月

TypeScript, React, ONNX Runtime Web, Web Worker

- 独立完成围棋 AI 应用的产品与工程闭环，覆盖对局交互、AI 对弈、用户数据链路与平台上线；上线 TapTap 后累计获得 82w+ 浏览量与 31w+ 游玩人次。
- 将 KataGo 原始权重转换为 ONNX 模型，并对不同模型大小与浏览器运行时兼容性进行验证，最终选用稳定小模型作为端侧推理方案。
- 基于 ONNX Runtime Web + Web Worker 实现浏览器端非阻塞推理，避免 AI 计算阻塞棋盘交互；相比云端 GPU 推理方案，降低部署成本并提升离线可用性。

HPCG 基准测试与异构集群性能调优

HPC 课程大作业

2025 年 07 月 - 2025 年 08 月

Linux, Slurm, MPI, OpenMP, CUDA, HPCG

- 独立完成异构集群下的 HPCG 编译、依赖配置、Slurm 作业运行与性能测试流程搭建。
- 在双 V100 GPU 环境下进行 Profiling 与参数调优，将 Grid Size 设为 128x128x128，并将 MPI/OpenMP 配比由 1×8 优化为 2×4，使性能由 118.8 GFLOP/s 提升至 238.9 GFLOP/s。

## 🔧 专业技能

AI / 大模型 LLM 应用架构、Agent 设计模式、RAG 系统、Prompt Engineering、Benchmark

Agent 工具链 MCP, CLI, Skill, OpenClaw, 工具调用、上下文与记忆策略

后端基础 Python (FastAPI), TypeScript, Pydantic, REST API, JSON, SSE, 登录态与异常处理

前端与桌面端 React, Electron, TypeScript, ONNX Runtime Web, Web Worker

端侧 AI TinyML 基础、模型剪枝、量化、了解端侧模型部署与模型压缩基本方法

工程化 Git, Linux / WSL, PowerShell, PyInstaller, Slurm, MPI/OpenMP, CUDA 基础

AI 工具 深度使用 Claude Code、Codex 等工具辅助需求拆解、代码生成、diff review 与测试验证